

FECAP

Fundação Escola de Comércio Álvares Penteado

Curso de Ciência da Computação
Inteligência Artificial e Aprendizado de Máquina

ENTREGA 1

Contagem Automática de Alimentos

Integrantes:

Felipe Vallim Soares — RA: 24026060
Guilhermy Mariano Lisboa Garcia — RA: 23025371
Gustavo Oliveira Demetrio — RA: 24026213
Saulo Pereira de Jesus — RA: 24026095

São Paulo — Março de 2026

1. INTRODUÇÃO

O presente projeto consiste no desenvolvimento de um sistema de visão computacional capaz de detectar, classificar e contar automaticamente embalagens de alimentos doados em um ambiente físico controlado. O cenário de captura utiliza uma rampa com fundo escuro, iluminação fixa e câmera posicionada sobre a rampa.

O sistema identifica três categorias de alimentos: arroz, feijão e outros (que engloba demais tipos de alimentos). O modelo utilizado é o YOLOv8n (nano), que realiza detecção e classificação em um único passo, fornecendo bounding boxes ao redor dos objetos — sendo adequado para contagem em tempo real.

Esta entrega inclui: Jupyter Notebook documentado com o pipeline completo, scripts Python modulares, modelo treinado, métricas de avaliação e demonstração em tempo real via webcam.

2. METODOLOGIA

2.1 Dataset e Augmentation

A base de dados foi construída com 88 imagens capturadas em ambiente controlado. Para expandir o dataset, foi implementado um pipeline de Data Augmentation com OpenCV. Cada imagem original gera 1 cópia redimensionada (640×640) e 10 variantes aumentadas, totalizando ~968 imagens. A divisão treino/validação segue proporção 80/20 com seed 42.

Técnica	Parâmetros	Prob.	Objetivo
Rotação	±20 graus	70%	Variação de ângulo
Flip	H, V, ambos	50%	Espelhamento
Brilho/Contraste	alpha [0.8,1.2] beta [-30,30]	50%	Variação de iluminação
Blur Gaussiano	kernel 3x3 ou 5x5	30%	Suavização
Ruído Gaussiano	sigma = 10	30%	Robustez a ruído
Zoom	escala [0.85, 1.15]	50%	Variação de escala

2.2 Mapeamento de Classes

O modelo classifica classes granulares que são mapeadas para as 3 categorias utilizadas na API. Quando a IA reconhece um item específico dentro da categoria "outros", essa informação é incluída no campo sub_item do payload. Caso não reconheça, o sub_item retorna "desconhecido".

Classe YOLO	ID	Categoria API	sub_item
arroz	0	arroz	arroz
feijão	1	feijão	feijão
açúcar	2	outros	açúcar
café	3	outros	café
macarrão	4	outros	macarrão

2.3 Arquitetura e Treinamento

O modelo utilizado é o YOLOv8n (nano) da Ultralytics, pré-treinado no dataset COCO e retreinado com transfer learning. Possui 73 camadas, aproximadamente 3 milhões de parâmetros treináveis, 8.1 GFLOPs de complexidade computacional e tamanho de ~6.3 MB.

Parâmetro	Valor
Épocas	30
Batch size	8
Tamanho de imagem	640 × 640 pixels
Modelo base	yolov8n.pt (pré-treinado COCO)
Framework	Ultralytics 8.4.24 + PyTorch 2.10.0
Hardware	CPU — 13th Gen Intel Core i5-13450HX
Tempo de treinamento	~57 minutos

2.4 Lógica de Contagem

A contagem durante a inferência em tempo real é realizada por uma lógica de estabilidade. Para que um item seja contabilizado, ele precisa ser detectado por 10 frames consecutivos com confiança mínima de 0.75. Após a contagem, um cooldown de 3 segundos é aplicado para evitar duplicatas. Caso nenhum objeto seja detectado ou haja troca de classe entre frames, o contador é resetado.

3. RESULTADOS E MÉTRICAS

As métricas a seguir foram obtidas na avaliação do modelo treinado sobre o conjunto de validação:



Métrica	Valor
mAP50	0.6337
mAP50-95	0.6337
Precision geral	0.543
Recall geral	0.985

O Recall obtido varia de 0.95 a 1.00 em todas as classes, indicando que o modelo detecta praticamente todos os itens presentes nas imagens. A Precision moderada (~0.52 a 0.59) é compensada na aplicação prática pela lógica de estabilidade implementada na inferência.

4. EVIDÊNCIAS DE EXECUÇÃO

As evidências abaixo demonstram a detecção e contagem em tempo real via webcam para cada uma das 3 categorias de alimentos.



4.1 Arroz



Payload retornado:

```
[CONTADO] arroz  conf=0.84  total=1
[PAYLOAD] {
  "label": "arroz",
  "sub_item": "arroz",
  "confidence": 0.8407,
  "timestamp": 1774728142.3
}
```

4.2 Feijão




Payload retornado:

```
[CONTADO] feijao  conf=0.88  total=2
[PAYLOAD] {
  "label": "feijao",
  "sub_item": "feijao",
  "confidence": 0.8803,
  "timestamp": 1774728148.5
}
```

4.3 Outros

A categoria "outros" engloba diversos tipos de alimentos identificados pelo modelo. Abaixo, um exemplo de detecção de um item classificado nesta categoria (macarrão).



Payload retornado:

```
[CONTADO] outros (macarrao)  conf=0.84  total=3
[PAYLOAD] {
  "label": "outros",
  "sub_item": "macarrao",
  "confidence": 0.8408,
  "timestamp": 1774728156.7
}
```

5. TECNOLOGIAS UTILIZADAS

Tecnologia	Finalidade
Python 3.10	Linguagem principal
YOLOv8 (Ultralytics 8.4.24)	Detecção de objetos em tempo real
PyTorch 2.10.0	Framework de deep learning
OpenCV	Processamento de imagem e data augmentation
NumPy	Manipulação de arrays
Jupyter Notebook	Documentação interativa do pipeline
FastAPI	API REST para integração (backend)

6. CONCLUSÃO

O objetivo desta entrega foi atingido: o modelo identifica visualmente três categorias de alimentos doados (arroz, feijão e outros), atendendo ao requisito da disciplina.

O pipeline foi implementado de forma modular, abrangendo coleta de imagens, data augmentation, treinamento com transfer learning, avaliação por métricas padronizadas e inferência em tempo real via webcam com contagem por estabilidade.

O Recall elevado garante que o sistema detecta praticamente todos os itens presentes, e a lógica de estabilidade assegura confiabilidade na contagem durante a aplicação prática.

Próximos Passos

Expandir o dataset com mais imagens e novos alimentos; integração completa com frontend e backend FastAPI; armazenamento de evidências e dados de contagem em nuvem; otimização do modelo para melhorar a Precision.